

摘要

随着大语言模型能力的快速提升，能够自主决策、自主持有资产并在区块链上自主交易的 AI Agent 正在成为链上经济中一类全新的参与者。Olas 等自主服务框架、Coinbase 提出的 x402 支付协议以及 ERC-8004 可信代理标准的相继出现，标志着“Agent 经济”已从概念进入实际部署阶段。然而，区块链账户天然匿名，链上只能观察到地址与交易，无法直接得知账户背后的操作者是人类、传统脚本 bot，还是具备自主决策能力的 AI Agent。这一“操作者类型不可知”的问题给链上风控、女巫攻击防御、空投治理与合规监管带来了新的挑战。现有研究或者停留在人类/bot 二分类框架，或者依赖 Web 域的浏览器自动化痕迹，均无法直接迁移到链上场景。本文调研了国内外链上账户识别与 AI Agent 检测的相关文献，发现当前研究还有所不足，又针对链上 AI Agent 行为指纹识别做了以下几个方面的工作：

(1) 构建了首个人类/脚本 bot/AI Agent 三类账户的链上真值数据集。提出“标签来源与行为特征解耦”的构建原则：agent 组取自 Olas 链上注册表与 x402 协议付款方（合并 27,900 个地址），bot 组通过 MEV 原子套利行为识别（48,883 个地址），human 组通过中心化交易所热钱包提币接收方反推（7,500 个地址），三组标签均不依赖任何待学习的行为特征。在 Base 链上以 8,064,661 个区块（187 天）的统一窗口采集三组活动流，最终得到 30,000 个有效样本。

(2) 设计了涵盖延迟、节律与突发性、交互结构以及 gas/nonce/value 发起上下文共六族 57 维的行为指纹特征体系。给出了两类泄漏特征的识别与剔除方法：窗口依赖特征在窗口不足一周时会退化为采集伪影，缺失模式特征会让模型依据“字段有没有值”而非行为本身作弊。由此定义了三组均可计算的纯行为特征集，作为主结论的依据。

(3) 提出了七组特征集递进消融的对照实验框架。以 XGBoost 三分类器为统一模型，从全特征集到纯时间行为集逐级收紧，隔离协议形态、采集窗口与缺失模式三类捷径的贡献。实验表明：在整族剔除全部 25 维泄漏与元特征后，纯行为特征集的 macro-F1 仍达 0.9812、agent 召回率 0.9879。该结论以绝对值为据：补充实验显示三类捷径互为冗余（单是缺失模式一族单独成模即达 0.9891），故天花板区间的消融差值不可解读为捷径贡献量。“链上 AI Agent 存在可测的行为指纹”这一核心论点成立。

(4) 设计了二分类对照实验揭示传统框架的失效模式。用 human/bot 二分类器对 18,305 个 agent 地址进行判别：在含结构性捷径特征的全特征集下，67.6% 被漏检为 human、32.4% 被判为 bot；在剔除全部捷径的纯行为特征集下，59.8% 被漏检为 human、40.2% 被判为 bot。七组特征集的漏检率落在 56.2%~67.6%；进一步做两组稳健性对照（控制组间采集不对称、整族剔除延迟族）后，该比例分别降至 54.2% 与 48.4%，说明具体数值依赖特征口径与采集设计。稳定

成立的是方向性结论：在所有口径下，agent 都被强行拆分到 human 与 bot 两侧而无一侧能正确容纳，且 48% ~ 68% 落向风控意义上最危险的 human 一侧，与 Web 域文献报道的 34.5% ~ 39.1% 处于同一量级甚至更高。这一失效源于二分标签体系中没有 agent 的归属，由此证明三分类框架在链上场景的必要性。

关键字：区块链，**AI Agent**，行为指纹，链上经济，数据建模

目录

摘要	I
目录	III
第一章 绪论	1
1.1 研究背景和意义	1
1.2 链上账户识别的研究现状和不足	2
1.3 行为指纹识别的原理和方法	3
1.3.1 基本原理	3
1.3.2 链上数据获取方法及特点	3
1.3.3 行为指纹识别的基本假设	3
1.4 论文的主要工作和研究成果	4
1.5 论文结构	4
第二章 区块链账户体系与 AI Agent 生态原理	5
2.1 以太坊账户模型与交易数据结构	5
2.2 Base 二层网络	5
2.3 链上 AI Agent 的三种生态形态	6
2.4 传统脚本 bot 与 MEV 套利	6
2.5 本章小结	7
第三章 三类账户真值数据集的构建	8
3.1 真值构建的基本原则	8
3.2 agent 组：协议注册与协议付款	8
3.2.1 Olas 注册表枚举	8
3.2.2 x402 付款方识别	8
3.2.3 ERC-8004 注册表及其空壳问题	9
3.3 bot 组：MEV 原子套利识别	9
3.4 human 组：交易所热钱包提币接收方反推	9
3.4.1 热钱包的行为学反推	9
3.4.2 提币接收方的逐级过滤	9
3.4.3 标签噪声的性质	10

3.5 统一活动流采集平台 10

3.6 本章小结 12

第四章 行为指纹特征体系的设计 13

4.1 设计原则与捷径风险 13

4.2 延迟族特征 14

4.3 节律与突发性族特征 14

4.4 交互结构族与元特征 15

4.5 泄漏特征的识别与剔除 15

4.6 本章小结 16

第五章 三分类模型设计与消融对照实验 17

5.1 模型总体设计 17

5.2 五阶段训练流水线 18

5.3 七组特征集消融实验设计 20

5.4 分布层面的可分性检验 21

5.5 三分类主结果 24

5.6 捷径贡献的消融分析 26

5.7 二分类对照实验 26

5.8 局限性讨论 27

5.9 本章小结 28

第六章 总结和展望 29

6.1 总结 29

6.2 展望 29

参考文献 30

第一章 绪论

1.1 研究背景和意义

自比特币^[1]与以太坊^[2]相继问世以来，区块链技术凭借去中心化、不可篡改与可编程等特性，在数字资产、去中心化金融等领域得到了广泛应用^{[3][5]}。与传统金融体系不同，区块链账户体系天然具有匿名性：链上只能观察到地址、交易与事件日志，账户背后操作者的真实身份、乃至操作者的“类型”，都无法直接得知。长期以来，链上参与者被默认划分为两类——人类用户与自动化脚本（bot），围绕这一二元划分形成了女巫检测、空投防刷、反洗钱等一系列安全实践^[4]。

然而，随着大语言模型能力的快速提升，一类全新的参与者正在进入链上经济：能够自主决策、自主持有资产并自主发起交易的 AI Agent。2022 年上线的 Olas（Autonolas）框架将“自主服务”注册为链上实体，由多签账户代表 agent 持续运行^[9]；2025 年 Coinbase 提出的 x402 协议复活了 HTTP 402 状态码，让 agent 能够在无人干预的情况下用稳定币为 API 调用逐笔付款^[10]；同年提出的 ERC-8004 标准则试图为跨组织的 agent 建立身份、声誉与验证三大链上注册表^[11]。近期研究已将这一趋势概括为“Agent 经济”的兴起^[12]。AI Agent 既不是传统意义上的人类用户，也不同于执行固定策略的脚本 bot：它由模型推理驱动，决策链路中包含链下推理延迟，行为模式兼具自动化的规律性与决策的灵活性。

操作者类型的不可知给链上生态带来了现实问题。其一，风控与合规视角下，交易所与监管机构需要区分自然人与自动化主体以履行了解客户义务；其二，治理视角下，空投与投票若无法识别 agent 集群，将被批量自主账户稀释，女巫攻击的成本被大语言模型进一步拉低^[6]；其三，“人格证明”（proof-of-personhood）方向的探索^{[7][8]}依赖生物特征或社交图谱等链下信息，在纯链上场景中并不可用。因此，仅凭链上公开可得的行为数据，判断一个地址背后是人类、脚本 bot 还是 AI Agent——即本文所研究的链上行为指纹识别问题——具有直接的应用价值。

从科学问题的角度看，该问题的核心是：AI Agent 的链上行为是否存在稳定、可测、且不依赖协议形态的“指纹”？如果存在，它与人类和脚本 bot 的差异体现在哪些维度、可以在多大程度上被机器学习模型捕获？本文围绕这一核心问题展开研究。

1.2 链上账户识别的研究现状和不足

链上账户识别的已有工作大致可以分为三条主线。第一条主线是地址聚类与身份关联。Meiklejohn 等人利用共同花费等启发式规则在比特币上实现了地址到实体的聚类^[16]；Victor 系统

整理了以太坊上的存款地址复用、空投多领等聚类启发式^[17]；Weber 等人则将图神经网络引入比特币反洗钱场景^[18]。这类工作回答的是“哪些地址属于同一实体”，而非“实体是什么类型”。

第二条主线是 bot 与欺诈账户检测。Hu 等人提出的 BERT4ETH 用预训练 Transformer 建模交易序列以检测钓鱼与欺诈账户^[19]；Niedermayer 等人对以太坊金融 bot 进行了系统检测与分类^[20]。MEV（最大可提取价值）方向的大量实证研究^{[21][22][23][24][25]}刻画了套利、抢跑、三明治攻击等典型 bot 行为，为构建 bot 真值样本提供了成熟的行为学依据。但这类工作均在人类/bot 二分类框架内展开，未考虑 AI Agent 这一新类别。

第三条主线是新兴的 AI Agent 检测。目前该方向的工作集中在 Web 域：文献^[15]在网页流量中识别 agent，仅用两个特征即达到 100% 召回——但其判别力来自浏览器自动化痕迹（Playwright 等框架不产生原始指针移动与滚轮事件流），这类痕迹在链上根本不存在；同一工作也表明，传统人类/bot 二分类器面对 agent 时漏检率高达 34.5%~39.1%。链上侧，文献^[13]对 ERC-8004 注册表进行了实证测量，发现仅 3%~15% 的注册具备有效元数据；文献^[14]分析了 x402 协议的安全性。据我们所知，目前尚无工作在链上给出人类/bot/agent 三类账户的行为学识别方案。

综上，现有研究存在以下不足：（1）缺少链上 AI Agent 的真值数据集，已有标签体系（如 Etherscan 标签云）不覆盖 agent 类别；（2）二分类框架在 agent 面前存在系统性失效风险，但失效的方向与程度在链上尚无定量结论；（3）链上特征工程中的泄漏问题——模型学到采集设计或协议形态而非行为本身——缺乏系统的识别与消融方法。本文针对这三点不足展开工作。

1.3 行为指纹识别的原理和方法

1.3.1 基本原理

行为指纹识别的基本原理是：账户的操作者类型决定其决策机制，决策机制在时间维度上留下可测的统计痕迹。脚本 bot 由确定性代码驱动，对链上机会的响应速度受限于网络延迟，通常在出块粒度内完成响应，且全天候运行、无昼夜节律；人类受生理与注意力约束，响应以分钟至小时计，活动呈现明显的昼夜节律与突发性；AI Agent 介于两者之间——它自动运行、无生理节律，但每次决策需经过链下模型推理，响应延迟高于纯脚本，且不同任务间的延迟方差更大。

据此，本文将地址在观察窗口内的活动时间戳序列作为一次“行为测量”，从相邻活动间隔（ Δt ）的分布形态、活动的昼夜与周内节律、突发性、交互结构等维度提取特征，再以监督学习方法训练三分类器。需要强调的是，链上时间戳以出块为粒度（Base 链为 2 秒）， Δt 是真实响应延迟的代理量而非其本身，这构成了方法的分辨率下限，也是第五章局限性讨论的对象之一。

1.3.2 链上数据获取方法及特点

链上历史数据的获取有三类典型途径。其一是自建全节点并重放区块，数据最完整但存储与同步成本极高；其二是使用商业数据仓库（如 Dune、BigQuery 公共数据集），查询便捷但受配额与口径限制，且难以逐地址回溯任意窗口；其三是使用去中心化归档查询网络，本文采用的 SQD 网络^[31]属于此类——它以列式存储提供区块、交易与日志的批量扫描接口，适合按地址批量抽取活动流。实验期间 SQD 网络出现持续的过载限流（HTTP 529），本文在采集端实现了指数退避重试与自适应节流，具体见 3.5 节。

1.3.3 行为指纹识别的基本假设

本文方法建立在以下基本假设之上。假设一：观察窗口内操作者类型不变，即一个地址在窗口内始终由同一类主体操作。假设二：真值标签的来源与行为特征解耦，标签不得由任何待学习的行为特征推导而来，否则将构成循环论证（详见 3.1 节）。假设三：观察窗口不短于一个完整星期，否则周内节律特征将退化为采集伪影（详见 4.5 节）。假设四：出块粒度构成时间分辨率下限，亚出块级的行为差异不可观测。

1.4 论文的主要工作和研究成果

本文调研了链上账户识别与 AI Agent 检测的国内外文献，针对 1.2 节所述不足，完成了以下四个方面的工作：

（1）构建了首个链上人类/脚本 bot/AI Agent 三类账户真值数据集。在“标签来源与行为特征解耦”原则下，agent 组取自 Olas 链上注册表与 x402 付款方（合并 27,900 个地址），bot 组通过 MEV 原子套利识别（48,883 个地址），human 组通过交易所热钱包提币接收方反推（7,500 个地址）；在 Base 链 8,064,661 个区块（187 天）的统一窗口内采集活动流，得到 30,000 个有效样本。

（2）设计了六族 57 维的行为指纹特征体系，并给出窗口依赖与缺失模式两类泄漏特征及协议形态元特征的识别与剔除方法，定义了三组均可计算的 32 维纯行为特征集（经特征筛选后实际入模 21 维）作为主结论依据。

（3）提出了七组特征集递进消融的对照实验框架，隔离协议形态、采集窗口与缺失模式三类捷径。在整族剔除全部捷径后，纯行为特征集仍达 macro-F1 0.9812、agent 召回 0.9879；并以“捷径单独成模”的补充实验说明三类捷径互为冗余、消融差值不可解读为贡献量，从而以绝对值证明“链上 AI Agent 存在可测行为指纹”的核心论点。

（4）通过二分类对照实验揭示传统框架的失效模式：human/bot 二分类器在全特征集下将 67.6% 的 agent 漏检为 human，在纯行为特征集下为 59.8%；在控制组间采集不对称与整族剔除延迟族两组稳健性对照下，该比例分别为 54.2% 与 48.4%。具体数值依赖特征口径，但方向稳

定：所有口径下都有 48%~68% 的 agent 落向 human 一侧，且没有任何一侧能正确容纳它——这是二分标签体系本身容纳不下 agent 的结构缺陷，从而论证了三分类框架的必要性。

1.5 论文结构

本文共分六章。第一章为绪论，介绍研究背景、现状与本文工作；第二章介绍区块链账户体系与链上 AI Agent 生态的基本原理；第三章给出三类账户真值数据集的构建方法与采集平台实现；第四章设计行为指纹特征体系并分析泄漏特征；第五章给出三分类模型、七组特征集消融与二分类对照实验的结果与讨论；第六章总结全文并展望后续工作。

第二章 区块链账户体系与 AI Agent 生态原理

本章介绍后续各章所依赖的基础知识：以太坊系账户模型与交易数据结构、本文选定的 Base 二层网络，以及链上 AI Agent 与传统脚本 bot 的生态形态。熟悉相关背景的读者可跳过本章。

2.1 以太坊账户模型与交易数据结构

以太坊^[2]采用账户模型，账户分为两类：外部账户（EOA）由私钥控制，能够主动发起交易；合约账户（CA）由代码控制，只能被交易或内部调用触发。每笔交易包含发起方、接收方、金额、gas 限额、gas 价格与 nonce 等字段，其中 nonce 是发起方账户的严格递增计数器，记录其累计发出的交易数。交易被打包进区块后获得区块高度与区块时间戳；时间戳以秒为单位，同一区块内所有交易共享同一时间戳。合约执行过程中可发出事件日志，日志记录合约地址、主题与数据，是观察账户“被动活动”（如收到代币转账）的主要途径^[5]。

对行为观测而言，上述结构意味着一个地址的链上足迹由三类记录构成：作为交易发起方（tx_from）、作为交易接收方（tx_to）、以及出现在事件日志中（event）。三类记录的可得字段不同：只有 tx_from 记录携带该地址自身的 nonce 与 gas 行为，事件记录则只有时间戳与主题。这一差异是第四章讨论“缺失模式捷径”的结构性根源。

2.2 Base 二层网络

本文选择 Base 链作为观测场地。Base 是基于 OP Stack 的以太坊二层网络^[32]，出块间隔固定为 2 秒。选择 Base 的理由有三：其一，出块间隔短，时间分辨率是以太坊主网（12 秒）的 6 倍，能够分辨 bot 与 agent 的亚分钟级响应差异——在 12 秒出块的主网上，两者的快速响应频带完全混叠；其二，Base 是当前 AI Agent 生态最活跃的部署地，Olas 注册表与 x402 协议的主要流量均在 Base 上；其三，Base 的历史数据在 SQD 归档网络中完整可查，满足 7 天窗口批量回溯的需要。

2.3 链上 AI Agent 的三种生态形态

本文考察的链上 AI Agent 生态包含三种形态，它们分别为 agent 真值构建提供了不同强度的标签来源。

(1) Olas 自主服务注册表。Olas (Autonolas) 框架^[9]将每个自主服务注册为链上 NFT，服务由链下的 agent 集群运行，链上以一个 Safe 多签账户作为服务的资产与交易主体。注册表合约提供服务总数与逐服务查询接口，可枚举全部服务并读取其多签地址。由于注册需要质押且服务需持续运行，Olas 标签的纯度最高，是本文 agent 组的核心来源。

(2) x402 协议付款方。x402^[10]是 Coinbase 于 2025 年提出的机器间支付协议：服务端对未付款请求返回 HTTP 402，客户端（通常是 agent）以稳定币签名付款后重试。链上可观察到的形态是付款方地址向服务方的 USDC 转账事件，且结算多经由固定的 facilitator 合约。文献^[14]对该协议的安全性进行了分析。x402 付款方以“正在为 API 调用逐笔付款”这一行为本身证明了其 agent 属性，标签强度高，但地址基数较小。

(3) ERC-8004 可信代理注册表。ERC-8004^[11]提出身份、声誉、验证三大注册表以支持跨组织 agent 协作。但实证研究^[13]表明其注册表中仅 3%~15% 的条目具备有效元数据，大量条目为测试或空壳注册。本文将其作为 agent 组的补充来源，并在 3.2 节报告其实际贡献。

2.4 传统脚本 bot 与 MEV 套利

与 AI Agent 相对照的是执行固定策略的传统脚本 bot，其中行为学特征最鲜明、且可被链上数据自证的是 MEV 原子套利 bot^{[21][22]}。这类 bot 监听多个去中心化交易所之间的价差，在同一笔交易内完成闭环兑换路径，赚取无风险价差；由于套利机会转瞬即逝，它们以极高频率发起交易，响应速度贴近出块粒度，且全天候运行^{[24][25]}。“同一交易内串联多次兑换”是纯行为学的识别依据，不依赖任何标签数据库，适合作为 bot 组真值来源（本文采用的具体判据及其相对完整闭环追踪的简化见 3.3 节）。

2.5 本章小结

本章介绍了以太坊账户模型下地址足迹的三类构成（tx_from/tx_to/event）及其字段差异，说明了选择 Base 链的三点理由（2 秒出块的时间分辨率、agent 生态密度、归档数据可得性），并梳理了 Olas、x402、ERC-8004 三种 agent 生态形态与 MEV 原子套利 bot 的行为学特征。这些背景构成第三章数据集构建的基础。

第三章 三类账户真值数据集的构建

真值数据集是本研究的地基，其构建难点在于：链上没有任何权威机构为“操作者类型”提供标签。本章首先提出构建原则，然后分别给出三组标签的采集方法，最后介绍统一活动流采集平台的实现与最终样本规模。

3.1 真值构建的基本原则

本文遵循“标签来源与行为特征解耦”的原则：任何一组的标签都不得由待学习的行为特征推导而来。若用“响应快、全天候”筛选 bot，再用响应延迟与昼夜节律特征训练分类器，则模型学到的只是筛选规则本身，评估指标将被虚假抬高——这是行为识别研究中典型的循环论证陷阱。因此，本文三组标签分别锚定在三类与行为特征正交的证据上：agent 组锚定协议注册与协议付款事实（2.3 节），bot 组锚定单笔交易内部的结构性套利证据（2.4 节），human 组锚定中心化交易所实名体系的提现关系（3.4 节）。唯一的例外是 human 组的两道活跃度过滤：其一，活跃度探针按探针段内自发交易命中数降序取前 7,500 个候选；其二，选样阶段剔除全窗口活动数超过 2,000 笔的地址（`config.HUMAN_MAX_ACTS_WINDOW`，约 10.7 笔/天，用于防止做市商程序混入）。二者都只使用粗粒度的活动计数，不涉及任何时间分布信息；但须强调这道上限只对 **human** 组生效（agent 与 bot 组的上限是每地址 3,000 条的采集封顶），它会系统性压低 human 组的活动频率、从而抬高该组的 Δt 量级——这与本文的核心判别方向同向，是一处必须披露的偏差来源，其影响列入 5.8 节局限性讨论。除此之外，昼夜节律类特征从未参与任何组的标签筛选。

3.2 agent 组：协议注册与协议付款

3.2.1 Olas 注册表枚举

Olas 注册表合约提供 `totalSupply` 与 `getService` 接口。本文枚举 Base 链 637 个与 Gnosis 链 3,804 个服务编号（其中 Gnosis 侧 239 个服务尚未部署多签），逐个读取服务的 Safe 多签地址，去重后共得到 4,159 个 agent 地址（Base 595 + Gnosis 3,564，与表 3.1 一致）。需要说明的是，跨链地址不能混用：Gnosis 链上的多签地址在 Base 链上通常没有任何活动，采集阶段将按目标链过滤（3.5 节）。

3.2.2 x402 付款方识别

x402 付款在链上表现为经由 facilitator 合约结算的 USDC 转账。本文以官方 facilitator 合约地址为锚点，从其结算事件中提取 504,668 个付款方地址，先以“窗口内累计付款不少于 20 笔”的门槛过滤，保留 23,897 个 x402 付款方写入清单（其中 248 个提交者被判定为零售型中继，其结算的支付计入负向证据）；“零售型提交者结算占比不超过 30%”的机器付款形态约束则在选样入池阶段执行——占比超限的 1,897 个、连同与 facilitator/Olas 清单重叠的 14 个被排除，实际可入池 21,830 个（3.5 节）。该来源的标签强度高：高频、小额、逐笔的付款行为本身即“机器为 API 逐笔付款”的直接证据。

3.2.3 ERC-8004 注册表及其空壳问题

本文同时抓取了 ERC-8004 身份注册表在 Base 链上的注册条目，共取得 8 条注册记录，按 **owner** 去重后仅剩 3 个唯一地址（其中一个地址独占 6 个 agentId）。这批条目的空壳化程度与文献^[13]报告的一致甚至更严重：注册条目高度重复，且全部无有效元数据。需要如实说明的是，本文对这 8 条记录的链上活跃度探测（eth_getTransactionCount）未成功返回，产物中 tx_count 均为 -1、tier 均标记为 unknown——因此“休眠”只是基于元数据缺失与注册高度重复的推断，并非活跃度实测结论。无论如何，该来源在“仅收活跃注册”的预过滤中被整批剔除，对 agent 组的新增贡献为 0。这一结果提示：在 agent 真值构建中，“注册过”远弱于“正在运行”与“正在付款”。前两个来源合并去重后（剔除与 bot 清单重叠的 156 个地址；与热钱包清单无重叠，与 facilitator 清单重叠的付款方保留在清单中、于选样入池阶段排除），agent 组共 27,900 个地址（x402 付款方 23,741 + Olas Safe 4,159）。

3.3 bot 组：MEV 原子套利识别

依据 2.4 节的行为学依据，本文在 Base 链的采集窗口内以隔桶抽样方式扫描去中心化交易所的兑换事件，将“同一交易内包含两次及以上兑换”的交易识别为原子多跳兑换，并对其发起方施加频次门槛以避免误收普通用户：要求单个 5,000 区块桶内至少发起 5 笔此类交易、活跃区块数不少于 3——经聚合器路由做一次多跳兑换的普通用户由此被排除，184,936 个候选发起方过滤后保留 49,039 个 bot 地址，再剔除与 agent 清单重叠的 156 个，得到 48,883 个。该判据是大规模套利生态测量研究^[24]所用识别逻辑的简化形式：未做逐笔的代币路径闭环追踪，以“单笔多跳 × 高频 × 多区块”的组合近似之，换取全窗口扫描的可行性。值得强调的是，识别依据是单笔交易内部的结构性证据，与响应延迟、活动节律等待学习特征无关，符合 3.1 节的解耦原则。

3.4 human 组：交易所热钱包提币接收方反推

3.4.1 热钱包的行为学反推

链上缺少权威的交易所热钱包标签（公开标签库对 Base 链覆盖不足），本文改用行为学反推：中心化交易所热钱包的可观测特征是“高出度散播”——短窗口内向大量互不相关的 EOA 转出原生代币，且自身几乎不调用合约。本文在窗口内等距铺设 6 个 20,000 区块的切片、扫描其中全部原生转账（首个切片即命中 4,947,106 笔交易、187,348 个发送方），按发送方聚合出度并施加上述形态约束，各切片结果合并去重后识别出 60 个热钱包地址（散播规模最大的三个地址分别覆盖 29,672、19,637 与 17,508 个不同接收方）。抽样核对其中头部地址在区块浏览器上的公开标注，确认均为主流交易所热钱包。

3.4.2 提币接收方的逐级过滤

以 60 个热钱包的转出交易接收方为候选（2,316,827 个地址），经逐级过滤得到 human 组：第一级按提币次数排序取前 15,000 个进入活跃度探针，并剔除已带其他组标签的地址（x402 付款方、MEV bot、Olas Safe、facilitator、热钱包本身），余 14,437 个；第二级为活跃度过滤，在窗口内均布 24 段 $\times$ 16,800 块（覆盖约 5%）的活跃度探针中统计各候选的自发交易命中数，8,132 个在探针段内有命中；第三级为排名截取：按探针命中数降序取前 7,500 个进入全窗口采集（7,500 为预设配额 6,000 的 1.25 倍冗余，是配置常数而非过滤后的自然余量）。需要说明的是，本组并未额外执行 `eth_getCode` 查询来剔除合约地址——EOA 属性由入选条件本身保证：候选必须在探针段内出现过 `tx_from` 记录，而在以太坊账户模型下只有外部账户能够主动发起交易，合约账户不可能出现在 `tx_from` 位置（2.1 节）。因此该判据在效果上等价于 EOA 过滤，代价是无法识别 EIP-7702 式的带码 EOA。

3.4.3 标签噪声的性质

必须指出，“从交易所提币”只是自然人的弱先验：提币接收方也可能是做市商程序或托管钱包。本文将 human 组的标签噪声水平估计为 5%~30%，并在第五章以标签噪声敏感性作为结论稳健性的检验维度之一。同时，为守住 3.1 节的解耦原则，本组筛选全程未使用任何昼夜节律类特征，`night_ratio`、`entropy_24h` 等特征的入模因此不构成循环论证——其中 `entropy_24h` 属窗口依赖特征，另按 4.5 节在主结论特征集中被剔除。

3.5 统一活动流采集平台

三组地址确定后，需要在同一观察窗口内以同一口径采集其活动流。本文实现了基于 SQD 归档网络^[31]的采集平台，要点如下。

（1）统一窗口与组内一致口径。三组均采用同一段 8,064,661 个区块（约 187 天，区块 42,755,201 至 50,819,862）的窗口；bot 与 agent 组的活动流由 `tx_from`、`tx_to`、`event` 三类记录合并而成（MEV bot 以 `tx_from` 为主、Olas 多签以 `tx_to` 为主、x402 付款方以 `event` 为主），

human 组仅采集其作为发起方的 tx_from 记录——人类的“决策时刻”体现在自己发起的交易上，被动收款反映的是对手方的节奏，纳入反而是噪声（实测该组仍混入 241 条事件记录、涉及 141 个地址，占全组 1,113,738 条记录的 0.02%，不影响统计量）；全部记录统一为“时间戳 + 活动类型 + 上下文字段”的宽表。这一组间口径差异连同分段方式差异（见下），意味着活动密度类特征不可入模，5.2 节 Phase 0 的规模类黑名单正为此设。窗口取整 7 天是硬约束：窗口跨不过一个完整星期时，周内熵特征恒为 0，会成为采集伪影（4.5 节）。

(2) 分段封顶采样（bot 组）。高频地址（如 MEV bot）在 187 天内可产生数百万条记录，全量抓取既不必要也不可行。平台对 bot 组在窗口内等距铺设 36 个小段，每段扫描 10,000 个区块（合计覆盖窗口的 4.5%），段起点以 $(W.len - 10,000)/35$ 为步长，使首段贴住窗口头、末段贴住窗口尾——若简单按 $W.len/36$ 取步长，末段将距窗口末端差 $1/36$ 个窗口，实际跨度被无谓削短；每段内按上限截取记录。分段保证了昼夜节律的均匀覆盖；跨段的时间间隔在特征计算时被显式剔除（seg 标记为真实采集断点，跨段不计 Δt ），避免人为大间隔污染 Δt 分布。agent 与 human 两组则全窗口连续采集、不分段：agent 的 x402 付款事件与 Olas 执行事件本身稀疏，human 更是天然低频，一旦分段每段都凑不出足够的相邻活动对， Δt 有效样本会跌破门槛而使整组在特征阶段被剔除。其采集流程伪代码如下：

```
step ← (W.len - 10,000) / 35           // 首段贴窗口头、末段贴窗口尾
for seg = 1 to 36 do                    // bot: 隔桶抽样，覆盖 4.5%
    range ← [W.start + (seg-1)·step, 同段起点 + 10,000 块]
    rows ← SQD.scan(range, addr ∈ bot, {tx_from, tx_to, event})
    append(rows → data/raw/base/bot/, seg ← seg) // 段号即真实断点
end for

// agent / human: 全窗连续, seg = 0
rows ← SQD.scan([W.start, W.end], addr ∈ agent, {tx_from, tx_to, event})
append(rows → data/raw/base/agent/, seg ← 0)
rows ← SQD.scan([W.start, W.end], addr ∈ human, {tx_from})
append(rows → data/raw/base/human/, seg ← 0)
```

(3) 过载自适应。实验期间 SQD 网络长时间处于过载状态，持续返回 HTTP 529/520 与连接层异常，全程吞吐仅 0.6~2.7 请求/秒。平台实现了指数退避重试（网络类错误预算 10 次，退避 1,2,4,...,120 秒，累计约 8 分钟）与乘性增加、加性减少的自适应节流（上限 3 秒）；实测发现该过载属服务端整体容量问题而非针对客户端的速率限制，也非本地网络或代理链路所致（直连与经代理的首字节时延分别为 2.7~4.0 秒与 2.5~2.9 秒，无显著差异）。整轮采集累计约 30 小时、约 30 万次请求，在过载条件下全部完成，无 chunk 因重试耗尽而失败。

(4) 跨链过滤与配额选样。agent 清单中 3,564 个 Gnosis 链地址在 Base 链上无活动，采集端按目标链剔除。选样采用配额制：预设 agent 13,000、bot 11,000、human 6,000，合计 30,000；任一组池子不足配额时，缺口按“采集成本从低到高”的顺序补给仍有余量的组，以保证

总量。本次运行中 bot 组因隔桶抽样仅覆盖 4.5% 窗口，48,883 个候选中只有 5,695 个在抽样段内攒够 20 条活动，缺口 5,305 由 agent 组补足（13,000 + 5,305 = 18,305）。此外，由于粗筛按未去重计数、写盘按真实去重数复核，两者口径不一致会造成少量地址在写盘阶段跌破门槛，故选样时按“2% 比例 + 每组固定 20 个”过选（实际选入 30,498 个，其中 human 组受合格池规模 6,112 封顶）、写盘时按目标数精确截断，使最终有效样本恰为 30,000。组内截取为固定种子（seed=42）洗牌后截断：三组候选池在截取前均以同一随机种子打散，因此截取本身不引入按清单顺序的系统性偏向，且完全可复现。真正的选择偏差来自入池条件而非截取方式——agent 池由“窗口内付款 ≥20 笔且零售型结算占比 ≤30%”的 x402 付款方构成、偏向高频付款方，human 池由活跃度探针降序取前 7,500 构成、偏向常用钱包，这两点与上述类别失衡一并在 5.8 节局限性中交代。

表 3.1 三组真值来源与识别方法汇总

组别	标签锚点	识别方法	地址数
agent	Olas 注册表	链上枚举 serviceId (Base + Gnosis) → Safe 多签地址	4,159 (Base 595 + Gnosis 3,564)
agent	x402 付款	facilitator 结算事件中的付款方 (504,668 经窗口内 ≥20 笔过滤)	23,897
agent	ERC-8004	身份注册表 (去重后仅 8 个唯一地址；活跃预过滤后新增 0)	0
agent	—	两来源合并去重 (剔除与 bot 组重叠 156 个)	27,900
bot	MEV 套利	单笔交易内 ≥2 次兑换 × 频次门槛 (≥5 笔、≥3 区块；184,936 候选过滤)	48,883
human	CEX 提现	热钱包行为学反推 → 2,316,827 个提币接收方逐级过滤	7,500

采集完成后，剔除窗口内去重活动少于 20 条的地址（短序列的间隔与节律统计量不稳定），得到最终有效样本 30,000 个，见表 3.2。三组样本量不均衡（agent 组因补足 bot 缺口而最多，占 61.0%），第五章将采用分层交叉验证与 macro-F1 指标以消除不均衡的影响。

表 3.2 活动流采集结果与有效样本量

组别	进入选样地址数	窗口内有活动	有效样本 (≥20 条)
agent	18,691	18,691	18,305

组别	进入选样地址数	窗口内有活动	有效样本 (≥20 条)
bot	5,695	5,695	5,695
human	6,112	6,112	6,000
合计	30,498	30,498	30,000

3.6 本章小结

本章在“标签来源与行为特征解耦”原则下构建了三类账户真值数据集：agent 组锚定协议注册与协议付款（27,900 个地址），bot 组锚定交易内套利结构（48,883 个地址），human 组锚定交易所提现关系（7,500 个地址）；并实现了统一窗口、分段封顶、过载自适应的活动流采集平台，在 Base 链 187 天窗口内得到 30,000 个有效样本。表 3.2 中“进入选样”与“有效样本”之差由两部分构成：3 个地址在去重后跌破 20 条门槛，其余 495 个是为抵消该损耗而预留的过选余量、在写盘达到配额后被截断——两者在漏斗报告中分列，以免被误读为静默丢弃。该数据集及其构建方法本身即是本文的贡献之一。

第四章 行为指纹特征体系的设计

特征体系决定了模型“能看到什么”，也决定了结论“能被什么污染”。本章先给出设计原则与捷径风险分析，再分族给出 57 维特征的形式化定义与装配算法，最后给出两类泄漏特征的识别与剔除方法——后者直接定义了第五章七组对照实验中的关键特征集。

4.1 设计原则与捷径风险

监督学习模型会利用一切与标签相关的信号，无论该信号是否反映研究者意图中的“行为”。结合第三章的数据构造过程，本文预判了三类捷径风险：其一是协议形态捷径——三组地址的足迹构成不同（MEV bot 几乎全是 tx_from 记录，x402 付款方几乎全是 event 记录，Olas 多签主要是被调用），刻画足迹构成的元特征可能让模型按“参与了哪类协议”而非“行为如何”分类；其二是采集窗口捷径——绝对跨度类特征受窗口设计影响；其三是缺失模式捷径——gas、nonce 等字段仅 tx_from 记录携带（2.1 节），对 agent 组缺失率达 98.5%~100%（按缺失敏感成员口径，见 4.5 节图 4.3），梯度提升树可以按“字段有没有值”分裂而绕过行为本身。

对应的设计原则是：特征全部保留、逐级消融。即不在特征工程阶段预先删除可疑特征，而是完整计算 57 维特征，再在实验阶段以递进收紧的特征子集隔离每类捷径的贡献（5.3 节）。这样既能报告“模型最好能到多少”，也能报告“刨掉一切捷径后还剩多少”。

记地址 a 在观察窗口 W 内的活动流为按时间升序的序列 $A(a) = \{(t_i, \text{type}_i, \text{ctx}_i)\}$ ，其中 t_i 为区块时间戳， $\text{type}_i \in \{\text{tx_from}, \text{tx_to}, \text{event}\}$ 为活动类型， ctx_i 为该类型可得的上下文字段（gas、nonce、金额、对手地址等）。全部特征均为 $A(a)$ 的函数，特征装配的总体算法如下：

算法 4.1 地址级特征装配

输入：地址 a 的活动流 $A(a)$ ；输出：57 维特征向量 $x(a)$

- 1: 将 $A(a)$ 按 t 升序排序；若 $|A(a)| < 20$ 则丢弃该地址
- 2: $\Delta \leftarrow \emptyset$
- 3: for 采样段 $s \in \text{seg}(a)$ do // 段号取自采集端标记，杜绝跨段伪间隔
- 4: $\Delta \leftarrow \Delta \cup \text{diff}(\{t_i : t_i \in \text{段 } s\})$
- 5: $\Delta_m \leftarrow$ 按交互对手分组后的组内相邻间隔 // 同目标“观察→决策→行动”
- 6: $x_{\text{lat}} \leftarrow$ 统计量(Δ) $\cup$ 三频带占比(Δ) $\cup$ 分位数(Δ_m) // 4.2 节
- 7: $x_{\text{rhy}} \leftarrow$ 突发性(Δ) $\cup$ 归一化熵(小时/周直方图) $\cup$ 夜间占比 // 4.3 节
- 8: $x_{\text{int}}, x_{\text{gas}}, x_{\text{nonce}}, x_{\text{val}}, x_{\text{meta}} \leftarrow$ 按字段可得性计算 // 4.4 节
- 9: return $x(a) = \text{拼接}(x_{\text{lat}}, x_{\text{rhy}}, x_{\text{int}}, x_{\text{gas}}, x_{\text{nonce}}, x_{\text{val}}, x_{\text{meta}})$

上述设计原则、特征分族与泄漏剔除的全景如图 4.1 所示：57 维特征分属六族——延迟（18 维）、节律与突发性（12 维）、交互结构（9 维）与 gas/nonce/value 发起上下文三族（合计 18 维）。主结论中剔除三类共 25 维：节律族中 6 维窗口依赖特征、3 维协议形态元特征（gas 族的主动交易占比与字段可得率 2 维、交互族的记录类型熵 1 维），以及 gas/nonce/value 三族中其余 16 维缺失敏感特征（4.5 节），保留的延迟（18 维）、节律（6 维）、交互结构（8 维）共 32 维构成纯行为特征集——该流向直接定义了第五章 5.3 节七组消融实验的特征子集边界。




图 4.1 57 维特征体系的分族构成与泄漏剔除流向

4.2 延迟族特征

延迟族共 18 维，是检验核心假设 H1（响应延迟是区分三类账户的核心信号）的直接载体。对算法 4.1 第 3~4 行得到的段内时间戳序列，定义相邻活动间隔：

$$\Delta t_i = t_i - t_{i-1}, \quad i = 2, 3, \dots, n \quad \text{式 (4.1)}$$

在 Δt 序列上计算均值 μ 、标准差 σ 、变异系数 $CV = \sigma/\mu$ 、各分位数（p01/p05/p10/p25/p50/p75）、对数中位数 $\text{median}(\log_1 \Delta t)$ 等统计量。其中 5% 分位数 $\Delta t(p05)$ 刻画该地址表现出的最快响应能力（“最快能有多快”），是地址级对比的核心单变量（5.4 节）。依据 Base 链 2 秒出块粒度，以 $b_1 = 2$ 秒、 $b_2 = 10$ 秒为界将间隔划分为三个假设频带，各频带占比为：

$$\varphi_{fast} = |\{ \Delta t < 2s \}| / n, \quad \varphi_{mid} = |\{ 2s \leq \Delta t < 10s \}| / n, \quad \varphi_{slow} = |\{ \Delta t \geq 10s \}| / n \quad \text{式 (4.2)}$$

其中机器带 ($\Delta t < 2$ 秒, 一个出块以内的贴块响应) 对应纯脚本的机械响应, 边界带 (2 ~ 10 秒) 覆盖“出块间隔 + 链下推理延迟”的假设区间, 是 agent 的预期主频带, 人类带 ($\Delta t \geq 10$ 秒) 对应人工操作节奏。若 agent 组在边界带的占比显著高于其余两组, 即构成 H1 的直接证据 (5.4 节将检验该预言——实测它并不成立, 判别力来自 Δt 分布的整体形态而非单一频带)。此外, 延迟族还包含“同目标响应间隔”子族 Δ_m (算法 4.1 第 5 行): 仅统计与同一交互对手的相邻间隔, 近似“观察对象状态变化→决策→行动”的闭环节奏, 比全局 Δt 更接近因果意义上的响应延迟。

4.3 节律与突发性族特征

人类活动在时间上呈突发性——活动成簇出现, 簇间有长间歇^[26], 并受昼夜节律支配^[27]; 脚本 bot 则近似匀速运行。本文采用 Goh 与 Barabási 提出的突发性系数^[26]:

$$B = (\sigma_{\Delta t} - \mu_{\Delta t}) / (\sigma_{\Delta t} + \mu_{\Delta t}) \in [-1, 1] \quad \text{式 (4.3)}$$

$B \rightarrow 1$ 表示高度突发 (事件驱动/人类形态), $B \rightarrow -1$ 表示严格周期 (定时任务形态), 泊松过程的 $B \approx 0$ 。昼夜节律以归一化 Shannon 熵刻画: 将活动按 UTC 小时分桶得到 24 维直方图占比 $p_1, \dots, p_{24}$, 计算

$$\tilde{H}_{24} = -(1 / \log_2 24) \sum_{k=1}^{24} p_k \log_2 p_k \in [0, 1] \quad \text{式 (4.4)}$$

归一化后 $\tilde{H}_{24} = 1$ 对应全天完全均匀 (全天候 bot 的典型形态), 值越低作息越鲜明。同理在周内 (day-of-week) 7 维直方图上定义归一化周内熵 $\tilde{H}_{\text{dow}}$ 。夜间占比定义为 UTC 0~6 时的活动占比——人类通常显著偏低, 但该定义依赖时区假设, 跨时区人群会引入偏差, 这一点在 5.8 节局限性中交代。活跃小时数 (有活动的不同小时数, 0~24) 刻画覆盖广度。需要预警的是: 周内熵要求窗口覆盖完整一周, 否则退化为常数 (4.5 节)。

图 4.2 将式(4.2)与式(4.3)的设计直觉可视化: (a) 三频带以 Base 链 2 秒出块为物理锚点——机器带对应贴块脚本响应, 边界带覆盖“出块间隔 + 链下推理延迟”的 agent 假设区间, 人类带对应人工操作节奏; (b) 突发性系数的三种典型形态——事件成簇、簇间长静默的序列 B 趋近 1, 泊松随机序列 $B \approx 0$, 严格周期的定时任务 B 趋近 -1。两组定义均不依赖任何标签信息, 其在真实三组数据上的实测分布见 5.4 节 (图 5.3、图 5.6)。




图 4.2 核心特征定义示意: (a) 三频带划分; (b) 突发性系数的三种形态

4.4 交互结构族与元特征

交互结构族刻画“和谁、以何种方式交互”：对手地址数、对手集中度、主动交易占比、事件参与占比、合约调用多样性等。gas 行为子族刻画发起交易时的 gas 出价策略（均值、方差、随行就市程度），nonce 子族刻画交易序列的连续性（nonce 连续占比、跳变占比、跨度），value 子族刻画转账金额分布（整数金额占比、金额熵）。元特征清单则直接记录足迹构成，共 3 维：主动交易占比（tx_from 记录占比）、gas 字段可得率与记录类型熵——前两者归在 gas 族名下、后者归在交互族名下，但语义上编码的是“数据可得性”而非行为。如 4.1 节所述，gas/nonce/value 三族对非发起型地址结构性缺失，元特征直接编码协议形态，二者都被列为受控对象而非直接弃用。

4.5 泄漏特征的识别与剔除

本文识别出两类必须在主结论中剔除的泄漏特征。

第一类是窗口依赖特征，共 6 维：3 维绝对跨度（首末活动跨度、活跃天数、最长静默时长）与 3 维周期覆盖度（周内熵、24 小时熵、活跃小时数）。前者的量纲由窗口长度决定；后者在窗口不足一周时退化——若窗口设计不足 7 天，周内熵将恒为 0，模型可依据“熵是否大于零”作弊。这正是 3.5 节坚持长窗口的原因：本次采用的 8,064,661 块（约 187 天）窗口使三组的首末活动跨度中位数分别达到 13.3 天（agent）、101.4 天（bot）与 150.4 天（human）（全量

30,000 个地址统计），均超过整周覆盖的下限，周期覆盖度特征不再退化为采集伪影。即便如此，这 6 维仍因量纲随窗口漂移而被列为受控对象、在主结论特征集中剔除。

第二类是缺失模式：gas/nonce/value 三族的缺失敏感特征对 agent 组缺失率 98.5%~100%。XGBoost 对缺失值有默认分裂方向（5.1 节），“有没有值”本身即可区分组别。第五章的消融实验将定量回答：剔除这两类特征后，判别力还剩多少。

图 4.3 给出该捷径的直接实证（只统计各族中真正缺失敏感的成员，剔除 gas 可得率、tx_from 占比、value 零值占比这三个恒可算的元特征）：agent 组的 gas 族缺失 98.5%、nonce 族缺失 100%、value 族缺失 99.97%（图中按整数位显示为 100%），而 bot 与 human 两组的 gas 族完全无缺失、nonce 族的缺失率也仅 0.04%（bot 组 2 个地址）与 0——“字段是否有值”本身即携带近乎完美的组别信息：单凭 nonce 一族即可几乎无误地把 agent 从另两组中分离出来。值得注意的是，value 族在另两组中也存在不同程度的缺失（bot 40.4%、human 43.1%），说明缺失并非 agent 独有；但其组间差异同样构成非行为信号，故三族一并列为受控对象，交由第五章消融实验定量隔离。




图 4.3 gas/nonce/value 三族特征的组内缺失率

剔除上述两类泄漏特征与 3 维元特征后（窗口依赖 6 维、元特征 3 维、缺失敏感 16 维，合计 25 维），剩余的延迟（18 维）、节律（6 维）、交互（8 维）三族共 32 维构成纯行为特征集（behavior 集，经第五章特征筛选后实际入模 21 维）——三组均可计算、只能用“行为本身不同”解释，是第五章主结论的依据。

4.6 本章小结

本章设计了六族 57 维行为指纹特征体系，给出了特征装配总算法与 Δt 、三频带占比、突发性系数、归一化活动熵等核心特征的形式化定义（式 4.1 ~ 4.4），并系统识别了协议形态、采集窗口、缺失模式三类捷径对应的泄漏特征，定义了 32 维纯行为特征集。特征全部保留、逐级消融的设计使捷径贡献成为可测量的对象。

第五章 三分类模型设计与消融对照实验

本章在第三章数据集与第四章特征体系之上完成模型设计、训练与验证。5.1 节给出模型总体设计与目标函数，5.2 节给出五阶段训练流水线的算法细节，5.3 节给出七组特征集消融实验的设计，5.4 节从分布层面检验可分性，5.5 节给出三分类主结果，5.6 节消融捷径贡献，5.7 节以二分类对照实验论证三分类的必要性，5.8 节讨论局限。

5.1 模型总体设计

模型选型上，本文采用单一 XGBoost 梯度提升树^[28]作为三分类器，而未采用 Stacking 集成或深度模型，理由有三。其一，本文的建模对象是每地址一行、57 维的静态统计量宽表而非原始事件序列，属于典型的中等规模表格数据（30,000 行 × 57 列）——在这一数据形态上梯度提升树至今对深度模型保持系统性优势^[29]；若要发挥序列模型的长处，需改以原始活动流为输入重新设计表示学习方案，这已超出本文“可解释的行为指纹”这一研究目标，留待后续工作；其二，XGBoost 对特征量纲不敏感、原生处理缺失值，且单模型结构保证了七组特征集消融的公平性——若引入多层集成，各特征子集下的模型容量将不可比；其三，树模型的增益重要性提供了与消融实验互补的可解释性证据（5.5 节）。模型总体架构与训练流程如图 5.1 所示。




图 5.1 模型总体架构与五阶段训练流程

XGBoost 属于加法树模型：对样本 x ，用 T 棵回归树的输出之和作为该样本在类别 c 上的打分

$$F_c(x) = \sum_{t=1}^T f_{t,c}(x), \quad f_{t,c} \in F_{tree} \quad \text{式 (5.1)}$$

其中 F_{tree} 为回归树函数空间。三类概率由 softmax 归一化给出 (multi:softprob 目标)：

$$P(c|x) = \exp(F_c(x)) / \sum_{c'} \exp(F_{c'}(x)), \quad c \in \{\text{human, bot, agent}\} \quad \text{式 (5.2)}$$

训练以多分类交叉熵损失加树复杂度正则为目标：

$$L = \sum_i \text{CE}(y_i, P(\cdot|x_i)) + \sum_t \Omega(f_t), \quad \Omega(f) = \gamma \cdot T_{leaf} + (\lambda/2) \|w\|^2 \quad \text{式 (5.3)}$$

其中 T_{leaf} 为叶子数、 w 为叶子权重向量。每次结点分裂按二阶近似下的增益选择：

$$\text{Gain} = (1/2) [G_L^2 / (H_L + \lambda) + G_R^2 / (H_R + \lambda) - (G_L + G_R)^2 / (H_L + H_R + \lambda)] - \gamma \quad \text{式 (5.4)}$$

其中 G 、 H 分别为落入左右子结点样本的一阶、二阶梯度和。与本课题直接相关的一个机制是缺失值默认方向：每次分裂时，XGBoost 为缺失该特征的样本学习一个默认走向（左或右子树，取增益更大者）。该机制让模型无需填充即可利用缺失信息——但也正因如此，4.1 节所述“缺失模式捷径”才成立：对 agent 组结构性缺失的 gas/nonce/value 特征，默认方向本身即可编码组别。这是 5.3 节 behavior 集必须整族剔除它们、而非简单填充的原因。

5.2 五阶段训练流水线

训练流水线共五个阶段（图 5.1）。Phase 0 为数据校验：检查标签合法性后按地址去重——同一地址若同时落入训练折与验证折，等于把答案抄给模型，属地址级泄漏；同时剔除活动总量、日均活动数等规模类特征（黑名单），防止模型按“活动多不多”而非“行为如何”分类。Phase 1 为四步特征选择，其算法如下：

算法 5.1 Phase 1 四步特征选择

输入： $X \in \mathbb{R}^{(n \times d)}$, y ; 参数 $\rho^* = 0.95$, $N = 40$, $m = 10$

- 1: 剔除常数列与全缺失列
- 2: $\text{imp} \leftarrow$ 浅层 XGBoost (120 棵/深 4) 的增益重要性
- 3: for 每对特征 (f_a , f_b) 满足 $|\text{Spearman}(f_a, f_b)| > \rho^*$ do
- 4: 剔除 imp 较小的一方 // 高相关对只留信息量大者
- 5: if 剔除零增益特征后剩余数 $\geq m$ then 执行剔除 // 防御性下限
- 6: 按 imp 降序截取前 N 个
- 7: return 保留特征集 F

Phase 2 为逐步网格搜索调参：将超参空间按语义分为 4 组（表 5.1），逐组扫描并将当轮最优并入基线，避免全组合网格的指数爆炸；每轮以分层 3 折交叉验证的 macro-F1 为准则。Phase 3 为分层 5 折袋外（OOF）评估，Phase 4 以 Phase 2 选定的超参在全量样本上重训并落盘。三个阶段的算法如下：

表 5.1 Phase 2 逐步网格搜索的超参空间（基线：树数 300，深度 4，学习率 0.1）

轮次	扫描超参	候选取值
1	max_depth / min_child_weight	$\{3, 4, 6\} \times \{1, 3\}$
2	subsample / colsample_bytree	$\{0.7, 0.9, 1.0\} \times \{0.7, 0.9, 1.0\}$
3	learning_rate / n_estimators	$\{0.05, 0.1, 0.2\} \times \{200, 400\}$
4	reg_lambda	$\{0.5, 1.0, 3.0\}$

算法 5.2 逐步调参与袋外评估（Phase 2~4）

输入：X_F, y; 基线超参 θ_0 ; 分组网格 $G_1 \dots G_4$

```

1:  $\theta \leftarrow \theta_0$ 
2: for r = 1 to 4 do                                // 逐组扫描，防组合爆炸
3:    $\theta \leftarrow \theta \oplus \operatorname{argmax}_{\{g \in G_r\}} \text{CV}_3 ( \text{XGB}(\theta \oplus g); \text{macro-F1} )$ 
4:    $P \leftarrow 0$  (n×3 概率矩阵)
5:   for (T_k, V_k)  $\in$  分层5折(X_F, y) do
6:      $m_k \leftarrow \text{XGB}(\theta).fit(T_k)$ 
7:      $P[V_k] \leftarrow m_k.predict\_proba(V_k)$  // 折外概率，无泄漏
8:    $\hat{y}_i \leftarrow \operatorname{argmax}_c P[i, c]$ ; 报告 macro-F1 与各类召回
9:   全量重训 XGB( $\theta$ ) 并落盘                      // 以 Phase 2 选定超参

```

袋外评估的关键在第 5~7 行：每个样本的预测概率都来自没见过它的折外模型，因此

$$P_{oof}[i] = m_{k(i)}.predict_proba(x_i), \quad i \in V_{k(i)} \quad \text{式 (5.5)}$$

在折内不含任何标签泄漏。需要如实指出其适用边界：Phase 1 的特征选择与 Phase 2 的调参都是在全量样本的标签上完成的，两者都会给该估计带来乐观偏差，严格无偏需把 Phase 1~2 整体嵌入外层折内重跑（嵌套交叉验证）。本文因主结论余量远大于该偏差量级（behavior 集 0.98 量级 vs 判定线 0.70）而保留现结构，并在此声明，不将式（5.5）称为无偏估计。评估主指标为宏平均 F1：

$$\text{macro-F1} = (1/3) \sum_c 2 P_c R_c / (P_c + R_c) \quad \text{式 (5.6)}$$

其中 P_c 、 R_c 为类别 c 的查准率与召回率。macro-F1 对三类等权，可消除样本量不均衡（agent/human/bot = 18,305/6,000/5,695）下多数类对指标的支配。缺失值以全体样本的特征中位数统一填充（在折划分之前计算——树模型本可不填充，统一填充是为了让不同特征集下的对照口径一致；中位数属低阶统计量，由此引入的折间信息可忽略，严格的流式部署应改为折内计算）；全部随机过程固定种子以保证可复现。依据研究设计，预设判定线为：纯行为集 $\text{macro-F1} \geq 0.7$ 且 agent 召回 ≥ 0.6 方可宣称三分类信号成立。

5.3 七组特征集消融实验设计

按 4.1 节“全部保留、逐级消融”原则，定义表 5.2 所列七组特征集，实验框架如图 5.2：同一份 30,000 样本、同一套折划分、同一条五阶段管线，唯一变量是喂入的特征子集。从 model 到 timing 逐级收紧：nometa 剔除协议形态捷径，nowin 剔除采集窗口捷径，clean 同时剔除两者，behavior 再剔除缺失模式捷径（4.5 节纯行为集），timing 只保留时间行为作为结论下界。定义特征子集 S 的捷径贡献（即被该子集排除的捷径所“虚增”的性能）为

$$\Delta_S = F1_{macro}(\text{model}) - F1_{macro}(S)$$

式 (5.7)



图 5.2 七组特征集消融实验框架

表 5.2 七组特征集定义（从宽到严）

特征集	定义	名义维数	入模维数
model	全部特征（主模型，含全部捷径）	57	32
latency	仅延迟族（单独检验 H1）	18	14
nometa	剔除元特征族（控制协议形态捷径）	54	37
nowin	剔除 6 维窗口依赖特征（控制采集窗口捷径）	51	29
clean	元特征与窗口依赖特征全剔（严对照）	48	34
behavior	再剔 gas/nonce/value 三族其余 16 维（纯行为集，主结论）	32	21
timing	仅延迟 + 节律（纯时间行为，结论下界）	24	18

表中入模维数为算法 5.1 筛选后实际进入模型的维数：高相关去重与零增益剔除在不同子集下命中不同，故入模维数与名义维数不成正比（如 model 集 57 维经 15 维高相关去重与 10 维零增益剔除后余 32 维入模；算法 5.1 的 Top-40 上限在七组中均未触发）。

5.4 分布层面的可分性检验

在训练模型之前，先直接观察三组的行为分布。图 5.3 给出三组相邻活动间隔 Δt 的合并分布与三频带划分（组内均值口径）：human 组质量压倒性集中于人类带（> 10 秒占 94.7%），机器带仅占 0.7%；bot 组在 10 秒以内的快速端拥有三组中最厚的质量（机器带 9.5%，为 agent 的 1.9 倍、human 的 14 倍），但其大部分间隔仍落在 10 秒以上（75.2%）；agent 组的机器带占比居中（5.0%），而 4.2 节预期为其主频带的 2~10 秒边界带占比是三组中最高（19.2%，对比 bot 15.3%、human 4.6%，见图 5.5）。就均值口径而言，频带假设得到了支持：agent 确实在 2~10 秒这一与 LLM 推理延迟量级相符的区间上富集。但须同时指出，该富集由部分地址主导而非全组普遍现象——agent 组 2~10 秒带占比的中位数仅 0.6%（bot 为 8.5%），均值与中位数的巨大落差说明组内异质性很强。因此本文的立场是：频带确实携带信号，但单一频带不足以支撑判别，可分性主要来自 Δt 分布的整体形态差异，这正是转向多维建模的动因。




图 5.3 三类账户相邻活动间隔 Δt 的分布与三频带

图5.4 地址级最快响应能力 $\Delta t(p05)$ 的经验累积分布




图 5.4 地址级最快响应能力 $\Delta t(p05)$ 的经验累积分布

图 5.4 从地址粒度刻画“最快能有多快”：过半 bot 地址（50.8%）的最快响应不超过 2 秒（一个出块），中位数恰为 2.0 秒；human 地址整体右移约 1.8 个数量级（中位数 135.6 秒，仅 12.1% 能达到贴块响应）；agent 地址的中位数（14.0 秒）介于其间，28.8% 具备不超过 2 秒的贴块响应能力。三组按对数尺度四分位距衡量的离散度分别为 2.28（agent）、2.00（bot）与 2.41（human）——human 组分布最宽，这与其样本构成有关：提币接收方中既有低频自然人，也有活跃度接近程序的常用钱包。图 5.5 的三频带占比进一步显示：agent 组的机器带均值占比（5.0%）低于 bot（9.5%）而高于 human（0.7%），2~10 秒带则以 19.2% 居三组之首。图 5.6 的突发性—节律联合分布中，agent 组的突发性系数中位数最高（+0.516），bot 与 human 依次为 +0.355 与 +0.332——agent 呈现最强的“成批爆发、间歇沉寂”形态，与 x402 付款经 facilitator 批量结算的机制一致；而 24 小时熵维度上 human 反而最高（0.830，对比 agent 0.701、bot 0.650）。需要说明的是，24 小时熵的组间关系与短窗口下的直觉相反：在 187 天的长窗口内，即使作息规律的自然人，其活动小时也会累积覆盖到全天多数时段，昼夜节律因而被拉平；该特征属 4.5 节界定的窗口依赖族，已在主结论特征集中剔除，此处仅作分布描述。

图5.5 三类账户的三频带活动占比对比（组内均值）
若 agent 组在 2 - 10s 带显著更高 → 支持 H1




图 5.5 三类账户的三频带活动占比对比

图5.6 突发性系数与 24 小时活动熵的联合分布
预期：bot 右下（均匀+周期），human 左上，agent 右上（均匀+突发）




图 5.6 突发性系数与 24 小时活动熵的联合分布

定量上，以两样本 Kolmogorov–Smirnov 统计量度量组间分布距离：

$$D_{a,b} = \sup_x | \hat{F}_a(x) - \hat{F}_b(x) | \quad \text{式 (5.8)}$$

其中 $\hat{F}$ 为经验累积分布函数。表 5.3 给出对数化最快响应特征上的两两检验结果：bot 与 human 的 KS 统计量达 0.524、bot 与 agent 达 0.361，单变量即明显可分；agent 与 human 的 KS 统计量仅 0.224，是三对中最小的。值得注意的是，在 3 万样本量下这一对的 p 值已降至

8.8×10^{-20} ，即统计上极显著。这正是大样本带来的判读变化：效应量（KS=0.224）与小样本试验中观测到的几乎一致，但显著性由不显著变为极显著——显著性回答的是“差异是否真实存在”，效应量回答的是“差异是否足以据此判别”。两者在此分离：agent 与 human 的分布差异真实存在，但其重叠程度决定了单变量阈值规则的判别力必然有限。因此区分 agent 与 human 仍须依赖多维特征的联合作用，这也解释了为何需要机器学习模型而非单一阈值规则。

表 5.3 两两组间分布检验 ($\log_{10} \Delta t(p05)$, KS 检验)

对比	n ₁	n ₂	KS 统计量	p 值
bot vs agent	5,695	18,305	0.361	$< 10^{-30}$
bot vs human	5,695	6,000	0.524	$< 10^{-30}$
agent vs human	18,305	6,000	0.224	8.77×10^{-20}

5.5 三分类主结果

表 5.4 给出七组特征集的袋外三分类性能。主结论以 behavior 集为准：macro-F1 达到 0.9812，agent 召回 0.9879，远超预设判定线（0.7 / 0.6），三分类信号成立。

表 5.4 七组特征集的分层 5 折袋外估计

特征集	macro-F1	agent 召回	bot 召回	human 召回
model	0.9997	1.000	0.999	1.000
latency	0.9537	0.971	0.936	0.946
nometa	0.9995	1.000	0.999	1.000
nowin	0.9996	1.000	0.999	0.999
clean	0.9996	1.000	0.999	1.000
behavior	0.9812	0.988	0.983	0.970
timing	0.9565	0.972	0.945	0.947

上述分数是否可信，首先取决于训练过程本身是否健康。图 5.7 对此做两方面核查，图形按 5.2 节相同的特征、超参数与折划分（seed=42）重放生成。图 5.7(a) 给出第 1 折逐轮的训练/验证 mlogloss：两条曲线在前 25 轮同步陡降，此后训练损失继续单调下行至 0.0033，而验证损失在第 93 轮触底 0.0523 后小幅回升，末轮为 0.0582，两线间隙扩大到 0.055——存在可观测的轻

度过拟合，本文不回避这一点。但须指出它的作用范围：过拟合体现在概率的锐度（对数损失）上，而非 argmax 判决上。以同一套折划分把树数分别设为 93、150、200、400 轮复测，袋外 macro-F1 依次为 0.9809、0.9813、0.9812、0.9809，全部落在 ± 0.0004 的带宽内，说明表 5.4 的排序类结论对容量配置并不敏感；反过来说，下游若要直接使用概率值（例如按固定阈值输出 agent 名单），则应在第 90 轮左右做早停或另做概率校准，而不能直接沿用本文的 200 轮模型。图 5.7(b) 的样本量学习曲线显示，验证 macro-F1 由 150 个子样本时的 0.8870 升至 30,000 个时的 0.9809，其中 150 $\rightarrow$ 1,500 段增益最陡（0.8870 $\rightarrow$ 0.9672），此后进入缓慢爬升：6,000 样本 0.9715、12,000 样本 0.9753、21,000 样本 0.9791、30,000 样本 0.9809（横轴为子样本总量，每折实际训练量为其 4/5）。更具说明力的是离散度的收敛—— $\pm 1\sigma$ 由 150 样本时的 ± 0.1098 收窄至 30,000 样本时的 ± 0.0021 ，量级下降近两个数量级；该收窄并非逐点单调（3,000 样本处 F1 由 0.9672 回落至 0.9636、21,000 处 ± 0.0017 略低于 30,000 处的 ± 0.0021 ），属于子采样与折划分带来的正常抖动，不改变总体趋势。这一对比同时给出两条结论：其一，本文的 0.9812 主结果建立在稳定的估计之上，而非小样本交叉验证的偶然波动；其二，曲线在两万样本后已明显趋缓，继续单纯扩充同质样本的边际收益有限，后续更值得投入的是定向补充边界形态（见下文图 5.10 的误分类结构）与扩展到其他链的泛化性验证。

图5.7 纯行为特征集 (behavior) 的训练过程核查




图 5.7 纯行为特征集的训练过程核查：(a) 逐轮 mlogloss；(b) 样本量-性能曲线




图 5.8 纯行为特征集下的三分类混淆矩阵

图 5.8 的混淆矩阵显示，30,000 个样本中共 498 例误分类（错误率 1.66%），且分布高度结构化：agent 与 human 之间 385 例（agent→human 214、human→agent 171），占全部错误的 77.3%；agent 与 bot 之间 99 例；human 与 bot 之间仅 14 例。这一结构与表 5.3 的分布检验完全吻合——KS 统计量最小的正是 agent-human 这一对（0.224），最大的是 bot-human（0.524），而混淆矩阵中这两对的错误数恰好一多一少。换言之，分布层面最难分的一对，在模型层面同样是残余错误的主要来源；bot 因其贴块响应与高频工程化节奏，反而是三类中最容易被正确识别的。剩余难点因此明确为：把行为节奏接近自然人的低频 agent 与常用钱包型 human 区分开。图 5.9 给出 model 集最终模型的特征重要性（XGBoost 增益）排序，前四位依次是 nonce 跨度 f_nonce_span （增益 329.0）、nonce 连续占比 $f_nonce_seq_ratio$ （327.7）、gas 字段可得率 $f_gas_avail_ratio$ （318.6）与对手地址熵 $f_to_entropy$ （297.9）——前三位全部是 4.1 节界定的结构性捷径，且彼此增益接近、合计占据首位集团；这恰说明捷径若不消融，将主导模型。需要说明的是，元特征 f_txfrom_ratio 与 $f_nonce_gap_ratio$ 虽属同类信号，但在算法 5.1 的高相关去重中分别被 $f_gas_avail_ratio$ 与 $f_nonce_seq_ratio$ 取代，故未出现在图中。




图 5.9 特征重要性排序 (model 集最终模型, XGBoost 增益)

图 5.8 的混淆矩阵与图 5.9 的重要性排序分别回答了"错在哪"与"看什么"。在此基础上, 图 5.10 将 argmax 硬判决背后的软概率展开: 按真实类别分组, 三类样本对真实类别的预测概率中位数分别为 human 0.9999、bot 1.0000、agent 1.0000, 直方图在对数计数轴下呈现右端单柱绝对主导的形态, 说明 0.98 量级的 F1 由高置信的正确判决构成, 而非勉强过线的边缘判决。498 例误分类并非随机散布, 而是集中在 agent-human 边界 (77.3%): 这类样本的共同形态是活动稀疏、间隔跨度大、交互对象少, 行为节奏落在“低频 agent”与“常用钱包型 human”的重叠区。这也正是后续扩充标注时最值得补强的边界形态——与其继续按现有分层扩大样本量 (学习曲线已趋缓), 不如定向采集这一重叠带的高置信样本。

图5.10 袋外预测概率分布 (behavior 特征集)
右端单柱占绝对主导 ☒ 高置信的正确判决, 而非勉强过线




图 5.10 袋外预测概率分布 (按真实类别分组, 对数计数轴)

图 5.11 的 One-vs-Rest ROC 曲线进一步说明, 上述排序能力对判决阈值并不敏感: AUC 依次为 human 0.9986、bot 0.9996、agent 0.9982。这意味着表 5.4 的 0.9812 并非特定阈值下的侥幸结果; 下游应用若需在查准率与召回率之间重新权衡 (如以更高查准率输出 agent 名单), 概率输出本身已提供充分的操作空间。

图5.11 One-vs-Rest ROC 曲线 (behavior 集 OOF)




图 5.11 三分类 One-vs-Rest ROC 曲线 (5 折 OOF 概率)

最后，图 5.12 将梯度提升的可加结构展开到单树层面，从“如何使用特征”的角度补全图 5.9 的全局视角。图中展开第 0 棵树的前三层：根节点是同目标响应间隔中位数 $f_m2_p50 < 9,788$ 秒（增益 5,560.7；图中 $cover=13,333$ 是 XGBoost 的二阶梯度和统计量而非样本数，树 0 的根节点实际经过全部 30,000 个训练样本），先把“节奏尺度在数小时以内”与“以天为单位”的两类账户分开；左分支继以调用方法多样性 $f_method_nunique < 9$ 细分——方法种类少而节奏快者落向工程化程序，方法种类多者再交由间隔标准差 f_dt_std 判别；右分支的次级节点则是对手集中度 $f_top_to_share < 0.9981$ （增益 963.2），即“是否几乎只与单一对手方交互”——这恰是 Agent 框架将目标合约固化在配置中留下的直接指纹。须注意该特征并未出现在图 5.9 中——图 5.9 画的是 model 集， $f_top_to_share$ 在该集合的高相关去重中已被剔除；但在本图所属的 behavior 集里，它正是增益最高的特征（增益 217.8，归一化重要性 0.576），两处证据因此是相互印证而非矛盾。整棵树的叶值量级不过 ± 0.3 ，最终判别力来自 200 轮 $\times$ 3 类共 600 棵树的加性叠加：单树的可读性与集成模型的非线性由此兼得。

图5.12 单棵提升树的结构展开 (behavior 集 · 第 0 棵 · 前 3 层)

每个内部节点是一次「特征 < 阈值」的二分判决；叶节点数值为该叶的输出分数




图 5.12 单棵提升树的结构展开 (behavior 集第 0 棵树前三层)

5.6 捷径贡献的消融分析

按式 (5.7) 将表 5.4 各行与 model 行相减，得到的差值都很小：剔除元特征族 $\Delta = +0.0002$ ，剔除窗口依赖特征 $\Delta = +0.0001$ ，严对照 clean 集（两类捷径全剔）仍达 0.9996、 Δ 仅 +0.0001；进一步剔除缺失模式后，behavior 集较全特征集共下降 0.0185。

但这些 Δ 不能被读作“捷径的贡献量”。原因有二：其一，model 集本身已达 0.9997，逼近指标上界，任何单项消融在此区间都缺乏分辨率；其二，也是更本质的，三类捷径对 agent 的指示作用彼此高度冗余——拿掉一条，剩下的会立刻补位，差值自然趋近于零。为把“冗余”与“无贡献”区分开，本文补做了一组正向实验：让每条捷径单独成模，在同一管线、同一折划分下观察它自己能达到什么水平，结果见表 5.6。

表 5.6 捷径单独成模的判别力 (分层 5 折袋外估计)

喂入模型的特征	名义维数	入模维数	macro-F1	agent 召回
仅协议形态元特征	3	2	0.7753	0.9999
仅窗口依赖特征	6	5	0.9099	0.9408
仅缺失模式特征 (gas/nonce/value)	16	14	0.9891	0.9998
仅 f_gas_avail_ratio 单列	1	1	0.5736	0.9999
仅 f_longest_silence_h 单列	1	1	0.7302	0.7787

表 5.6 给出了明确的答案：缺失模式一族单独成模即达 macro-F1 0.9891、agent 召回 0.9998，甚至高于主结论 behavior 集的 0.9812；单独一列 f_gas_avail_ratio 的 agent 召回也有 0.9999。也就是说，三条捷径中的任意一条都足以独立锁定 **agent**，因此表 5.4 中 $\Delta \approx 0$ 所证明的是捷径之间的冗余性，而不是它们没有判别力。本文据此修正结论的引用方式：主结论只引用 **behavior** 集的绝对值，不引用任何消融差值。

在这一口径下，核心论点的证据链是：behavior 集在整族剔除了 25 维泄漏与元特征（窗口依赖 6 维、元特征 3 维、gas/nonce/value 三族 16 维，其中 15 维缺失敏感）之后，仅凭三组均可计算的 21 维入模特征，仍取得 macro-F1 0.9812、agent 召回 0.9879。这一绝对值无法用“参与了哪类协议”“采集窗口多长”“字段有没有值”中的任何一条解释，因为这三类信号已经整族不在模型里。

延迟族单独成模（latency 集）即达 macro-F1 0.9537；纯时间行为（timing 集）达 0.9565，略高于 latency 集，说明在延迟族之外补入节律族仍有小幅增益。这两个下界共同支撑 H1：仅凭响应延迟及其时间结构，三分类即可达到 0.95 以上的 macro-F1，时间行为是本任务的核心信号源——其作用方式主要体现为 Δt 分布的整体形态差异，而非任何单一频带的富集（5.4 节）。

5.7 二分类对照实验

为论证三分类框架的必要性，本文在同一管线上构造了如下对照（图 5.1 中 Phase 5）：

```
算法 5.3 二分类对照实验 (Phase 5)
1: D2 ← 仅保留 human 与 bot 样本
2: m2 ← 以算法 5.1~5.2 同流程在 D2 上训练二分类器
3: for 每个 agent 地址 a do ŷ(a) ← m2.pred( x(a) )
4: 统计 agent 被判为 human / bot 的去向占比
```

即模拟“现有工作只知道人类与 bot 两类”的情形，再让这样的分类器面对从未见过的 agent。该对照在七组特征集上各自运行（与三分类共用特征子集），对全部 18,305 个 agent 地址判别，结果如表 5.5：七组口径下都有多数 agent 被漏检为 human（表 5.7 会进一步检验这一多数关系的边界）。

表 5.5 human/bot 二分类器对 agent 地址的判别去向（按特征集）

特征集	agent → 判为 bot	agent → 判为 human
model（全特征，含捷径）	32.4%	67.6%
nometa（剔元特征）	33.0%	67.0%

特征集	agent → 判为 bot	agent → 判为 human
nowin（剔窗口依赖）	39.7%	60.3%
clean（严对照）	42.1%	57.9%
latency（仅延迟族）	42.0%	58.0%
behavior（纯行为，主结论口径）	40.2%	59.8%
timing（纯时间行为）	43.8%	56.2%

表 5.5 的七组结果落在一个相对窄的带内：agent 被漏检为 human 的比例介于 56.2% ~ 67.6%，被判为 bot 的比例介于 32.4% ~ 43.8%。含结构性捷径的特征集（model/nometa）漏检率最高（67.6% / 67.0%），逐级剔除捷径后降至 56% ~ 60% 一带。

这七组并不构成七个独立证据，须审慎解读。model、latency、nometa、nowin、clean、behavior、timing 七套特征集全部包含完整的 18 维延迟族——消融只改动延迟族以外的部分，因此七组共享同一个判别内核，其一致性在相当程度上是结构决定的。要检验“失效是否与特征口径无关”，必须做一组把延迟族整族拿掉的对照；同时，5.8 节(3) 指出的采集不对称也直接作用于延迟族，需要一并控制。本文补做的这两组对照见表 5.7。

表 5.7 二分类失效形态的两组稳健性对照（均以 behavior 集为基线）

对照	入模维 数	三分类 macro-F1	agent → 判为 human
基线：behavior 集（表 5.4 / 5.5 口径）	21	0.9812	59.8%
控制采集不对称：三组 Δt 一律 winsorize 至 bot 段 长上限 20,000 秒	24	0.9705	54.2%
控制特征口径：整族剔除 18 维延迟族（仅余节律 6 + 交互 8）	10	0.8824	48.4%

两组对照给出的边界是清晰的。控制采集不对称后，三分类主结论仅由 0.9812 降至 0.9705，仍远超 0.70 的预设判定线——“链上 AI Agent 存在可测行为指纹”这一核心论点不依赖组间采集口径的差异；但二分类漏检率同步由 59.8% 降至 54.2%。整族拿掉延迟族后，漏检率进一步降到 48.4%，即不再构成多数。由此必须把结论收敛为两条：站得住的是——无论何种特征口径，agent 都被强行拆分到 human 与 bot 两侧，没有任何一侧能正确容纳它，且落入 human 一侧的比例始终在 48% ~ 68% 之间、与 Web 域报道的 34.5% ~ 39.1% 处于同一量级甚至

更高；站不住的是——“漏检比例稳定落在 56.2%~67.6% 的窄区间”与“失效方向与特征可得性完全无关”这两种更强的说法，因为该多数方向主要由延迟族驱动，并对采集口径敏感。

值得注意的是，本文观测到的漏检率在多数口径下不低于文献^[15]在 Web 域报道的 34.5%~39.1%，而该文献的场景是 agent 在网页上刻意模仿人类交互，本文的场景中 agent 并未做任何伪装。其机制在于：链上 agent 的活动在“稀疏、低频、间隔跨度大”这些粗粒度统计量上与自然人高度重叠——这与 5.5 节混淆矩阵中 agent-human 边界贡献 77.3% 的残余错误、以及表 5.3 中该对 KS 统计量最小（0.224）三处证据完全一致。三者相互印证：agent 与 human 的行为分布本就最为接近，一旦缺少 agent 这一类标签，分类器只能把它并入最相近的既有类别，即 human。

综合表 5.5 与表 5.7，可以给出一个更保守但更站得住的结论：二分类框架的失效源于标签空间缺失——agent 在“人类 / bot”的二分标签里没有正确的位置，无论喂入何种特征，分类器都只能把它错误归并；而在本文考察的全部特征口径下，都有相当大比例（48%~68%）的 agent 被归并到风控意义上最危险的一侧，即被当作普通用户而豁免于针对性监测。归并比例的具体数值依赖特征口径与采集设计，但“必然错误归并”与“大比例落向 human”这两点在所有口径下稳定成立。因此，无论下游风控以哪种特征口径部署，人类/bot 二分类框架都不敷使用，三分类是必要的。

5.8 局限性讨论

本文实验存在以下已知局限。（1） Δt 是响应延迟的代理量：链上无法回溯触发事件（HTTP 请求在链下，内存池数据难以历史回放），亚秒级差异在整秒时间戳下永不可见；对 x402 付款方，事件时间戳记录的是 facilitator 批量结算上链的时刻而非 agent 决策时刻，批量结算带来同秒爆发与批次间长间隔，稀释了推理延迟的可见性；完整的因果延迟测量需引入内存池数据或合约事件配对。（2）human 组标签为弱先验，5%~30% 的标签噪声虽经稳健性设计缓解，完整的噪声注入敏感性实验仍是后续工作；夜间占比等特征的 UTC 时区假设对跨时区人群亦有偏差。更需要特别披露的是该组独有的一道活跃度上限：选样阶段剔除了全窗口活动数超过 2,000 笔的候选（3.1 节），而 agent 与 bot 两组的上限是每地址 3,000 条的采集封顶。实测三组的活动数上界因此分别为 human 1,997、bot 2,997、agent 3,000。由于在固定窗口内活动数与 Δt 量级近似成反比，这道只对 human 生效的上限会系统性抬高该组的 Δt ，方向与本文的核心判别方向一致，构成一处对主结论有利的偏差。其影响未被单独消融（活动数本身已列入规模类黑名单不入模，但 Δt 无法与之解耦），严格的做法是对三组施加同一上限后重采，属后续工作。（3）采集口径存在组间不对称，且其影响并不限于节律特征，而是直接作用于本文的核心信号 Δt ：bot 组按 36 段 $\times$ 10,000 块隔桶抽样（覆盖窗口的 4.5%），因 f01 只在同一段内计算 Δt （3.5 节），该组段内 Δt 的物理上限约为 $10,000 \times 2 = 20,000$ 秒；而 agent 与 human 两组全窗连续扫描， Δt 上限是整个 187 天窗口。实测三组的“段内最大 Δt ”中位数分别为 bot 7,496 秒、agent

208,362 秒、human 1,677,752 秒，相差逾两个数量级；延迟族的尾部统计量（p75 / mean / std / iqr）与 f_longest_silence_h 因此对 bot 组被结构性截断——这是采集设计，不是行为差异。本文以表 5.7 第二行定量控制该因素：把三组 Δt 一律 winsorize 至 20,000 秒后重训（winsorize 而非丢弃，样本量保持 30,000 不变，避免二次选择偏差），三分类 macro-F1 由 0.9812 降至 0.9705、二分类漏检率由 59.8% 降至 54.2%。即主结论稳健，但表 5.5 的具体数值含约 1 个百分点（macro-F1）与约 5.6 个百分点（漏检率）的采集口径成分。彻底的修正需把三组统一到同一采样密度重采，属后续工作；活动密度类特征则已列入黑名单不入模。（3b）三组样本量存在明显失衡：agent 18,305、human 6,000、bot 5,695，agent 占比达 61.0%。其成因是 bot 组受隔桶抽样限制，48,883 个候选中仅 5,695 个在抽样段内攒够 20 条活动，未能填满 11,000 的预设配额，缺口按再平衡规则由 agent 组补足。本文以 macro-F1 为主指标、辅以分层交叉验证以消除多数类对指标的支配，表 5.4 中三类召回率（0.988 / 0.983 / 0.970）亦无系统性偏向少数类的迹象，故该失衡不构成对主结论的威胁；但严格对称的三组等量设计需要提高 bot 组的窗口覆盖率重新采集，属后续工作。此外，组内截取虽为固定种子洗牌后截断（3.5 节），不引入按清单顺序的偏向，但入池条件本身带有选择性——x402 池要求窗口内付款 ≥ 20 笔、偏向高频付款方，human 池由活跃度探针降序取前 7,500、偏向常用钱包，样本代表性受此限制。（4）2 秒出块是分辨率下限，结论不能直接外推到 12 秒出块的以太坊主网。（5）行为指纹存在对抗性：知晓检测规则的 agent 可注入人为延迟与节律伪装，检测与伪装的博弈超出本文范围，但值得指出伪装需付出响应速度与运营成本的代价。

5.9 本章小结

本章给出了以单一 XGBoost 多分类器为核心的模型设计（目标函数式 5.1 ~ 5.4）与防泄漏的五阶段训练流水线（算法 5.1 ~ 5.2），并完成多层验证：分布检验显示 agent 与 human 在单变量上的效应量最小（KS = 0.224）、必须多元建模；七组特征集消融（图 5.2）在整族剔除 25 维泄漏与元特征后，纯行为集仍取得 macro-F1 0.9812、agent 召回 0.9879，核心论点成立——该结论以绝对值为据，而非以消融差值为据：表 5.6 显示三类捷径互为冗余，单是缺失模式一族单独成模即达 0.9891，故天花板区间的 $\Delta \approx 0$ 只能说明冗余，不能说明无贡献；学习曲线显示 $\pm 1\sigma$ 随样本量由 ± 0.110 收窄至 ± 0.002 ，结果稳定，同时 mlogloss 曲线暴露出轻度过拟合，但其影响限于概率校准而非 argmax 判决；二分类对照实验（算法 5.3）证明二分类框架在任一特征口径下都无法正确处置 agent——48% ~ 68% 的 agent 被归并到 human 一侧（表 5.5、表 5.7），失效源于标签空间缺失而非特征不足，三分类框架必要。

第六章 总结和展望

6.1 总结

本文围绕“链上 AI Agent 是否存在可测的行为指纹”这一核心问题，完成了从真值构建、特征设计到模型验证的完整研究。主要工作与结论如下：

(1) 在标签与行为解耦原则下构建了首个链上三类账户真值数据集：agent 组 27,900 个地址（Olas 注册表 + x402 付款方；ERC-8004 经活跃预过滤贡献为 0），bot 组 48,883 个地址（MEV 原子套利识别），human 组 7,500 个地址（交易所热钱包提币反推），并在 Base 链 8,064,661 个区块（约 187 天）的统一窗口内采集活动流，得到 30,000 个有效样本。

(2) 设计了六族 57 维行为指纹特征体系与特征装配算法，系统识别了协议形态、采集窗口、缺失模式三类捷径，定义了 32 维纯行为特征集。

(3) 设计了以单一 XGBoost 多分类器为核心的模型方案与防泄漏五阶段训练流水线，以七组特征集递进消融加两组稳健性对照验证：整族剔除 25 维泄漏与元特征后，纯行为集仍达 macro-F1 0.9812、agent 召回 0.9879；并指出三类捷径互为冗余、消融差值在天花板区间不可解读，主结论应以该绝对值为据——链上 AI Agent 的行为指纹真实存在且可被稳定捕获。

(4) 二分类对照实验表明，传统 human/bot 分类器无论在何种特征口径下都无法正确处置 agent：七组特征集加两组稳健性对照中，被漏检为 human 的比例落在 48%~68%，与 Web 域报道的 34.5%~39.1% 处于同一量级甚至更高。具体比例依赖特征口径与采集设计，但“必然错误归并、且大比例落向 human 一侧”这一方向在所有口径下稳定成立——其根源是二分标签空间中缺少 agent 的位置，三分类框架在链上场景因此具有必要性。

6.2 展望

后续工作可在以下方向展开。其一，真延迟测量：引入内存池观测或“合约事件—响应交易”配对，将 Δt 从代理量升级为因果响应延迟。其二，标签噪声敏感性：对 human 组注入 5%~30% 的受控标签噪声，给出性能衰减曲线，量化弱先验标签的影响。其三，跨链泛化：在出块间隔不同的链（以太坊主网 12 秒、更快的新兴 L2）上检验特征体系的可迁移性，探明时间分辨率对可分性的约束。其四，对抗鲁棒性：形式化“伪装成本”——agent 模仿人类节律需要牺牲多少响应速度与吞吐，检测器在对抗下的性能下界如何。其五，在线部署：将离线批量特征流水线改造为流式计算，支持地址的实时评分与增量更新，为空投治理、风控接入等应用提供工程基础。其六，对称重采：把三组统一到同一采样密度与同一活动数上限重新采集，以彻底消

除 5.8 节(2)(3) 两处口径不对称，使表 5.5 的漏检率成为不含采集成分的净量。其七，嵌套交叉验证：把特征选择与调参整体嵌入外层折内重跑，给出严格无偏的泛化估计（5.2 节）。

参考文献

- [1] Nakamoto S. Bitcoin: A peer-to-peer electronic cash system[EB/OL]. 2008. <https://bitcoin.org/bitcoin.pdf>.
- [2] Wood G. Ethereum: A secure decentralised generalised transaction ledger[R]. Ethereum Project Yellow Paper, 2014.
- [3] 袁勇, 王飞跃. 区块链技术发展现状与展望[J]. 自动化学报, 2016, 42(4): 481-494.
- [4] 韩璇, 袁勇, 王飞跃. 区块链安全问题: 研究现状与展望[J]. 自动化学报, 2019, 45(1): 206-225.
- [5] 邵奇峰, 金澈清, 张召, 等. 区块链技术: 架构及进展[J]. 计算机学报, 2018, 41(5): 969-988.
- [6] Ferrara E, Varol O, Davis C, et al. The rise of social bots[J]. Communications of the ACM, 2016, 59(7): 96-104.
- [7] Borge M, Kokoris-Kogias E, Jovanovic P, et al. Proof-of-personhood: Redemocratizing permissionless cryptocurrencies[C]// 2017 IEEE European Symposium on Security and Privacy Workshops (EuroS&PW). IEEE, 2017: 23-26.
- [8] Worldcoin Foundation. The Worldcoin whitepaper[EB/OL]. 2023. <https://whitepaper.worldcoin.org>.
- [9] Valory AG. Autonolas whitepaper v1.0[EB/OL]. 2022. <https://olas.network/documents/whitepaper>.
- [10] Coinbase. x402: An open protocol for internet-native payments[EB/OL]. 2025. <https://www.x402.org>.
- [11] ERC-8004: Trustless agents[EB/OL]. Ethereum Improvement Proposals, 2025. <https://eips.ethereum.org/EIPS/eip-8004>.
- [12] The Web4 agent economy[EB/OL]. arXiv preprint arXiv:2606.25876, 2026. <https://arxiv.org/abs/2606.25876>.
- [13] ERC-8004 可信代理注册表的链上实证测量[EB/OL]. arXiv preprint arXiv:2606.26028, 2026. <https://arxiv.org/abs/2606.26028>.
- [14] x402 机器间支付协议的安全性分析[EB/OL]. arXiv preprint arXiv:2607.19545, 2026. <https://arxiv.org/abs/2607.19545>.
- [15] Web 流量中 AI Agent 的检测研究[EB/OL]. arXiv preprint arXiv:2607.26935, 2026. <https://arxiv.org/abs/2607.26935>.
- [16] Meiklejohn S, Pomarole M, Jordan G, et al. A fistful of bitcoins: Characterizing payments among men with no names[C]// Proceedings of the 2013 Internet Measurement Conference. ACM, 2013: 127-140.
- [17] Victor F. Address clustering heuristics for Ethereum[C]// Financial Cryptography and Data Security (FC 2020). Springer, 2020: 617-633.
- [18] Weber M, Domeniconi G, Chen J, et al. Anti-money laundering in bitcoin: Experimenting with graph convolutional networks for financial forensics[EB/OL]. arXiv preprint arXiv:1908.02591, 2019.
- [19] Hu S, Zhang Z, Luo B, et al. BERT4ETH: A pre-trained Transformer for Ethereum fraud detection[C]// Proceedings of the ACM Web Conference 2023 (WWW). ACM, 2023: 2189-2197.

- [20] Niedermayer T, Saggese P, Haslhofer B. Detecting financial bots on the Ethereum blockchain[C]// Companion Proceedings of the ACM Web Conference 2024 (WWW). ACM, 2024.
- [21] Daian P, Goldfeder S, Kell T, et al. Flash Boys 2.0: Frontrunning in decentralized exchanges, miner extractable value, and consensus instability[C]// 2020 IEEE Symposium on Security and Privacy (SP). IEEE, 2020: 910-927.
- [22] Qin K, Zhou L, Gervais A. Quantifying blockchain extractable value: How dark is the forest?[C]// 2022 IEEE Symposium on Security and Privacy (SP). IEEE, 2022: 198-214.
- [23] Torres C F, Camino R, State R. Frontrunner Jones and the raiders of the dark forest: An empirical study of frontrunning on the Ethereum blockchain[C]// 30th USENIX Security Symposium. USENIX Association, 2021: 1343-1359.
- [24] McLaughlin R, Kruegel C, Vigna G. A large scale study of the Ethereum arbitrage ecosystem[C]// 32nd USENIX Security Symposium. USENIX Association, 2023: 3295-3312.
- [25] Wang Y, Chen Y, Wu H, et al. Cyclic arbitrage in decentralized exchanges[C]// Companion Proceedings of the Web Conference 2022 (WWW). ACM, 2022: 12-19.
- [26] Goh K I, Barabási A L. Burstiness and memory in complex systems[J]. EPL (Europhysics Letters), 2008, 81(4): 48002.
- [27] Jo H H, Karsai M, Kertész J, et al. Circadian pattern and burstiness in mobile phone communication[J]. New Journal of Physics, 2012, 14(1): 013055.
- [28] Chen T, Guestrin C. XGBoost: A scalable tree boosting system[C]// Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. ACM, 2016: 785-794.
- [29] Grinsztajn L, Oyallon E, Varoquaux G. Why do tree-based models still outperform deep learning on typical tabular data?[C]// Advances in Neural Information Processing Systems 35 (NeurIPS 2022), Datasets and Benchmarks Track. 2022.
- [30] Pedregosa F, Varoquaux G, Gramfort A, et al. Scikit-learn: Machine learning in Python[J]. Journal of Machine Learning Research, 2011, 12: 2825-2830.
- [31] SQD. SQD network documentation[EB/OL]. 2025. <https://docs.sqd.ai>.
- [32] Base. Base network documentation[EB/OL]. 2025. <https://docs.base.org>.